

Lab5 : Principal Component Analysis : PCA

Dans cet atelier nous allons créer un modèle pour prédire les valeurs des chiffres manuscrites. Pour ce faire nous allons faire appel à un dataset prédéfini dans scikit-learn :

```
from sklearn import datasets
ds=datasets.load_digits()
```



Afficher les différentes informations du ds

```
ds.keys()
print(ds.keys())
print(len(ds.data))
print(len(ds.target))
data=ds.data
target=ds.target
```

data Les données sous forme d'un tableau 2D ($n_{\text{samples}} \times n_{\text{features}}$) → chaque image aplatie en vecteur de 64 pixels (8×8)

target Les étiquettes (le chiffre que représente chaque image : 0, 1, 2, ..., 9)

frame Optionnel, tableau complet avec les données (pas toujours présent)

feature_names Noms des caractéristiques (ici, "pixel_1", ..., "pixel_64")

target_names Noms des classes (tableau [0,1,2,3,4,5,6,7,8,9])

Afficher les dimensions des images contenues dans data

Afficher les données de toutes les images

```
Data
Data.shape
```

shape=(x, y) veut dire que vous avez x image dont chaque image est définie par y1/y2 soit y pixels en tous. Avec $y=y1*y2$


- si on veut afficher la première image => `data[0]` => 64 valeurs

- si on veut l'afficher sous forme matricielle => data[0].reshape(8,8)

pour afficher les 24 premières image pixellisé

```
from mport matplotlib.pyplot as plt
from sklearn.datasets import load_digits
# Afficher les 24 premières images en disposition 6 lignes x 4 colonnes
fig, axes = plt.subplots(6, 4, figsize=(10, 12))
for i, ax in enumerate(axes.flat):
    if i < 24:
        ax.imshow(ds.data[i].reshape(8, 8), cmap='Blues', interpolation='nearest')
        ax.axis('off')

plt.tight_layout()
plt.show()
```



Afficher les valeurs des chacune des images manuscrites

?

Que veut dire la standardisation des données ?

Quelles differences entre minmax scaler et standard scaler ?

Appliquer le standard scaler sur les données du dataset

Pensez vous que cette application aurez de l'impact sur le modèle ? justifiez votre réponse

```
from sklearn.linear_model import LogisticRegression
from sklearn.preprocessing import StandardScaler
scaler=StandardScaler()
ds_scaler=scaler.fit_transform(data)
```

Entrenez le modèle

```
X_train,X_test,Y_train,Y_test= train_test_split(ds_scaler,target,random_state=0,test_size=0.3)
model=LogisticRegression()
model.fit(X_train,Y_train)
```

Calculer le score du modèle

Quelle métrique est utilisé par le score pour mesurer le performance du modèle de régression logistique ?

Quelle sera cette métrique si nous avons un modèle de régression ?

Appliquer le socre sur les données de test

Dans un modèle de régression logistique, que peut-on conclure si le score sur l'ensemble d'entraînement (train) est différent du score sur l'ensemble de test ? Et que signifie un écart important entre ces deux valeurs ?

Afficher le rapport de classification du résultat de votre modèle

```
pred_train=model.predict(X_train)
pred_test= model.predict(X_test)
from sklearn.metrics import classification_report
result=classification_report (Y_train,pred_train)
print(result)
```


Afficher la matrice de confusion

```
from sklearn.metrics import confusion_matrix
confusionMatix=confusion_matrix(Y_train,pred_train)
confusionMatix
```

Représenter graphiquement la matrice de confusion

```
plt.figure(figsize=(10, 10))
sns.heatmap(confusionMatix, annot=True, fmt=".2f")
plt.show()
```

Pour la classe 1 donner les TP,TN,FP, et FN



Construire un nouveau dataframe qui combine les données avec les valeurs de leurs colonnes

```
import pandas as pd
df=pd.DataFrame(data=data,columns=ds.feature_names)
df
```

Afficher par classe le nombre réel des images

Afficher par classe le nombre réel des images d'entraînement

Afficher par classe le nombre réel des images de test

Réduction du Dimensionnement

```
from sklearn.decomposition import PCA
pca=PCA(0.95)
data_pca=pca.fit_transform(data)
```

Quelle est la nouvelle dimension du dataset

Réentraîner le modèle sur les nouvelles données

Comparer les résultats obtenus sur les données avant et après le redimensionnement. Que constatez-vous ?